



Teknoloji Fakültesi

BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

DERİN ÖĞRENME İLE SEÇİÇİ GÜRÜLTÜ ENGELLEME

BİTİRME PROJESİ

Bilgisayar Mühendisliği Bölümü

DANIŞMAN

Dr. Öğr. Üyesi Ali Sarıkaş

İSTANBUL, 2026

MARMARA ÜNİVERSİTESİ
TEKNOLOJİ FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ

Marmara Üniversitesi Teknoloji Fakültesi Bilgisayar Mühendisliği Öğrencileri Kerem TUTUMLU ve Melih GÖÇMEN tarafından “**DERİN ÖĞRENME İLE SEÇİCİ GÜRÜLTÜ ENGELLEME**” başlıklı proje çalışması, 12.06.2026 tarihinde savunulmuş ve jüri üyeleri tarafından başarılı bulunmuştur.

Jüri Üyeleri

Prof. Dr. Kazım Yıldız
Marmara Üniversitesi

(İMZA).....

Dr. Öğr. Üyesi Ali SARIKAŞ
Marmara Üniversitesi

(Danışman)

(İMZA).....

Arş. Gör. Damla MENGÜŞ
Marmara Üniversitesi
Arş. Gör. Damla MENGÜŞ
Marmara Üniversitesi

(İMZA).....

(İMZA).....

ÖNSÖZ

Proje konusunun belirlenmesinden raporlama aşamasına kadar geçen süreçte, bilgi ve tecrübeleriyle bize yol gösteren, karşılaştığımız teknik zorluklarda yönlendirici fikirleriyle desteğini esirgemeyen ve özellikle Tübitak 2209-A başvurusu fikriyle ufkumuzu genişleten fikirlerinden ötürü değerli danışman hocamız Dr. Öğr. Üyesi Ali SARIKAŞ'a en içten teşekkürlerimizi sunarız.

Ayrıca, çalışmalarımız sırasında fikir alışverişinde bulunduğumuz arkadaşlarımıza ve eğitim hayatımız boyunca bizden maddi ve manevi desteklerini hiçbir zaman esirgemeyen ailelerimize teşekkürü bir borç biliriz.

İÇİNDEKİLER

1. GİRİŞ.....	1
1.1. Problem Tanımı ve Motivasyon.....	1
1.2. Seçici Gürültü Engellemenin Zorlukları.....	2
1.3. Projenin Katkıları.....	3
1.4. Proje Raporunun Organizasyonu.....	3
2. TEKNİK ARKA PLAN ve İLGİLİ ÇALIŞMALAR.....	4
2.1. Ses Kaynak Ayırıştırma.....	4
2.1.1. Klasik Yaklaşımlar.....	4
2.1.2. Derin Öğrenme Tabanlı Ayırıştırma.....	4
2.1.3. Zaman-Frekans Maskeleye.....	4
2.2. U-Net Mimarisi.....	5
2.3. FiLM: Feature-wise Linear Modulation.....	5
2.4. Sorgu-Koşullu ve Hedef Kaynak Ayırıştırma.....	6
2.5. STFT ve Spektrogram Temsili.....	6
2.6. Değerlendirme Metrikleri.....	7
2.6.1. SI-SDR.....	7
2.6.2. Precision, Recall ve F1.....	7
2.7. Veri Kümeleri.....	7
3. Yöntem.....	8
3.1. Sistem Genel Bakışı.....	8
3.2. Spektrogram Sözleşmesi.....	9
3.3. Anlık Karışım Üretici (SeparationMixer).....	9
3.4. FiLM-Koşullu U-Net Mimarisi.....	10
3.4.1. Kodlayıcı, Darboğaz ve Kod Çözücü.....	10
3.4.2. Her Seviyede FiLM Koşullandırması.....	10
3.4.3. Çıkış Maskesi.....	11
3.4.4. Algılama Başlığı.....	11
3.4.5. Eğitim Sarmalayıcısı.....	12
3.5. Kayıp Fonksiyonları.....	12
3.5.1. Çok-Çözünürlüklü L1 (Ayırıştırma).....	12
3.5.2. İkili Çapraz Entropi (Algılama).....	13
3.5.3. Focal Loss ve Gradyan Çöküşü.....	13
3.5.4. Bileşik Kayıp.....	13
3.6. Eğitim Prosedürü.....	13
3.7. Çıkarım Hattı.....	14
3.7.1. Algılama.....	14
3.7.2. Bastırma.....	14
3.8. Web Uygulaması.....	14
4. İteratif Geliştirme Süreci (v1.0–v2.8).....	14
4.1. v1.0 — İlk Çalışan Temel Model.....	15

4.2. v2.0 — Agresif Artırmanın Yol Açtığı Eğitim Çöküşü.....	15
4.3. v2.1 — Artırmanın Düzeltilmesi ve Çıkarım Normalizasyonu.....	16
4.4. v2.2 — Tam-Kodlayıcı FiLM, Çok-Çözünürlüklü Kayıp ve Sıkı Algılama.....	16
4.5. v2.3 — negative_prob Düşürme ve FSD50K'nın Dahil Edilmesi.....	16
4.6. v2.4 — Minimum Klip Tabanı ve Allow-List.....	17
4.7. v2.5 — Ağırlıklı Zor-Negatif Eğitim (Geçersiz Dosya).....	17
4.8. v2.6 — Algılama Başlığı.....	18
4.9. v2.7 — Focal Loss ve Gradyan Çöküşü.....	18
4.10. v2.8 — BCE Algılama Kaybı ve FSD50K'nın Çıkarılması.....	18
5. Sonuçlar ve Değerlendirme.....	19
5.1. Versiyonlar Arası Karşılaştırma.....	19
5.2. SI-SDR Analizi.....	21
5.3. Algılama F1 Analizi.....	21
5.4. Per-Class Analiz ve Excel Çıktısı.....	21
6. Tartışma.....	22
6.1. SI-SDR Neden Negatif Kalıyor?.....	22
6.2. Spektrogram-Faz Sınırlaması.....	22
6.3. Hayalet Yanlış-Pozitif Problemi.....	22
6.4. Algılama ve Ayrıştırma Arasındaki Denge.....	22
7. Gelecek Çalışmalar.....	23
8. Sonuç.....	23
KAYNAKLAR.....	25

ÖZET

DERİN ÖĞRENME İLE SEÇİCİ GÜRÜLTÜ ENGELLEME

Bu çalışmada, bir ses kaydı içerisinde bulunan belirli bir ses sınıfının seçici olarak bastırılmasını sağlayan, sorgu ile koşullanan bir derin öğrenme tabanlı kaynak ayırma sistemi tasarlanmış, iteratif olarak geliştirilmiş ve nicel olarak değerlendirilmiştir. Önerilen sistemin temelinde, hangi ses sınıfının ayıklanacağı bilgisini bir one-hot sorgu vektörü aracılığıyla alan ve bu bilgiyi FiLM katmanları ile evrimsel öznitelik haritalarına enjekte eden bir U-Net mimarisi yer almaktadır. Ağ, giriş karışımının logaritmik genlik spektrogramından, sorgulanan sınıfa ait yumuşak bir zaman-frekans maskesi üretir; bu maske ile karışımın genlik spektrogramı çarpılarak hedef kaynağın kestirimi elde edilir.

Eğitim verisi, ESC-50, UrbanSound8K ve FSD50K veri kümelerinden anlık olarak üretilen karışımlardan oluşur. Böylece sınıf sayısı ölçeklenebilir kalır ve sabit bir veri dosyasına bağımlılık ortadan kalkar. Sistemin gerçek dünyadaki kullanımını mümkün kılmak için, yüklenen ses/video içeriğindeki mevcut sınıfları tespit eden bir algılama başlığı mimariye entegre edilmiş ve bir web uygulaması geliştirilmiştir.

Çalışmanın ayırt edici yönü, tek bir nihai modelin sunulması değil, v1.0'dan v2.9'a uzanan on bir sürümlük iteratif bir mühendislik sürecinin sistematik biçimde belgelenmesidir. Her sürümde gözlemlenen başarısızlık modları (veri artırma kaynaklı eğitim çöküşü, FSD50K kaynaklı hayalet yanlış pozitifler, focal loss gradyan çöküşü vb.) kök-neden analizi ile incelenmiş ve bir sonraki sürümün tasarım kararlarını yönlendirmiştir. Algılama başarımı, ölçülen makro-F1 değeri bakımından v2.6'daki 0,17 seviyesinden v2.8'de 0,32'ye yükselmiş; v2.9'da öğrenilemeyen sınıfların ayıklanması ve eşik optimizasyonu ile bu değerin daha da artırılması hedeflenmiştir. Ayırıştırma kalitesi SI-SDRi metriği ile ölçülmüş; metriğin tüm sürümlerde negatif çıkması, spektrogram-faz yeniden kullanımının yapısal bir sınırlaması olarak tartışılmıştır.

Anahtar Kelimeler: ses kaynak ayırıştırma, seçici gürültü engelleme, sorgu-kışullu ayırıştırma, FiLM, U-Net, zaman-frekans maskeleme, SI-SDR, ses olayı algılama.

ABSTRACT

SELECTIVE NOISE CANCELLING WITH DEEP LEARNING

In this study, a query-conditioned, deep learning-based source separation system enabling the selective suppression of a specific sound class within an audio recording was designed, iteratively developed, and quantitatively evaluated. At the core of the proposed system lies a U-Net architecture that receives information on which sound class to separate via a one-hot query vector and injects this information into convolutional feature maps using FiLM layers. The network generates a soft time-frequency mask for the queried class from the logarithmic magnitude spectrogram of the input mixture; the target source is estimated by multiplying this mask with the magnitude spectrogram of the mixture.

The training data consists of mixtures generated on-the-fly from the ESC-50, UrbanSound8K and FSD50K datasets. Thus, the number of classes remains scalable, and the reliance on a static dataset file is eliminated. To enable the real-world application of the system, a detection head that identifies the present classes within the uploaded audio/video content was integrated into the architecture, and a web application was developed.

The distinguishing aspect of the study is not the presentation of a single final model, but the systematic documentation of an iterative engineering process spanning eleven versions from v1.0 to v2.9. The failure modes observed in each version (e.g., augmentation-induced training collapse, FSD50K-induced phantom false positives, focal loss gradient collapse) were investigated through root-cause analysis and guided the design decisions of the subsequent versions. Detection performance, in terms of the measured macro-F1 score, increased from 0.17 in v2.6 to 0.32 in v2.8; further improvement of this value was targeted in v2.9 through the elimination of unlearnable classes and threshold optimization. Separation quality was evaluated using the SI-SDRi metric; the negative values of the metric across all versions were discussed as a structural limitation of spectrogram-phase reuse.

Keywords: sound source separation, selective noise suppression, query-conditioned separation, FiLM, U-Net, time-frequency masking, SI-SDR, sound event detection.

June, 2026

Melih GÖÇMEN

Kerem TUTUMLU

KISALTMALAR

FiLM : feature-wise linear modulation

TABLO LİSTESİ

3.1 Spektrogram sözleşmesi parametreleri.	19
4.1 Sürümlerin üst düzey özeti. (F1 ve SI-SDRi değerleri ilgili sürüm bölümlerinde açıklanan ölçüm koşullarına aittir.)	26
4.2 v2.4 algılama eşik taraması (cap × top_k).	30
4.3 v2.6 algılama eşik taraması (aynı checkpoint, 200 sentetik karışım)	31
4.4 v2.8 eğitim sırasında kayıp bileşenlerinin değişimi.	33
4.5 v2.9 hiperparametre değişiklikleri (v2.8'e göre).	34

ŞEKİL LİSTESİ

2.1 FiLM dönüşümü. Koşullandırma girdisi (sorgu gömme q), kanal-bazlı ölçek γ ve kaydırma β parametrelerini üretir; öznitelik haritası x önce γ ile çarpılır, ardından β eklenir	6
2.2 Kullanılan veri kümeleri ve birleşik kelime dağarcığı. ESC-50 ve UrbanSound8K çekirdek 56-sınıflı dağarcığı oluşturur; FSD50K bir dönem (v2.3–v2.6) dahil edilmiş, hayalet yanlış-pozitifler nedeniyle v2.8’de çıkarılmıştır	8
3.1 Uçtan uca sistem hattı (pipeline): ham ses kümelerinden web uygulamasındaki çıkarıma kadar veri akışı.	8
3.2 SeparationMixer bir eğitim örneğini nasıl üretir. Klip seçimi, toplama, gürültü artırma ve normalizasyondan sonra negative_prob olasılığıyla negatif (hedef sessizlik) ya da pozitif (hedef stem) bir örnek olarak dallanır.	10
3.3 FiLM-koşullu darboğaz üzerine eklenen algılama başlığı (v2.6 ve sonrası). Darboğaz zaten sorguya koşullu olduğundan küresel ortalama havuzlama sınıf-bilinçli bir vektör üretir; son sigmoid, sorgulanan sınıfın mevcudiyet olasılığını verir.	11
3.4 FiLM-koşullu U-Net mimarisi. Kodlayıcı (mavi) her seviyede FiLM ile sorguya koşullanır; atlama bağlantıları (kesikli) sınıfa-özgü öznitelikleri kod çözücüye (yeşil) taşır. Sorgu gömmesinden türetilen FiLM (γ , β) parametreleri bütün kodlayıcı seviyelerine ve darboğaza enjekte edilir. Darboğazdan dallanan algılama başlığı (mor) sorgulanan sınıfın mevcudiyetini kestirir.	12
3.5 Web uygulaması arayüzü ekran görüntüsü: yükleme, algılanan sınıf onay kutuları, temizlenmiş çıktı (kavramsal ekran görüntüsü).	15
5.1 Sürümler arası algılama F1: tam kelime dağarcığı vs. yerel-sınıf allow-list (üretilen şekil).	20

5.2 Sürümler arası toplam yanlış pozitif (FP) sayısı. v2.3'ten v2.8'e kadar FP hacmi 1092'den 456'ya gerilemiştir; en büyük düşüş, FSD50K'nın tamamen kaldırıldığı v2.8'de gerçekleşir. 20

5.3 Sürümler arası ortalama SI-SDRi (dB). Metrik tüm sürümlerde negatiftir; bu, spektrogram-faz yeniden kullanımının yapısal bir sınırlamasıdır. v2.6'nın görece yüksek değeri, hedefin baskın olduğu FSD50K örneklerinin sayısal yanlışlığından kaynaklanır... 21

1. GİRİŞ

İşitsel ortamlar, insan deneyiminin ayrılmaz bir parçasıdır. Akıllı telefonlar, dizüstü bilgisayarlar ve giyilebilir cihazlar aracılığıyla her gün milyarlarca saatlik ses ve video içeriği kaydedilmekte, iletilmekte ve tüketilmektedir. Bu içeriklerin büyük çoğunluğu, birden fazla ses kaynağının üst üste bindiği karmaşık akustik ortamlarda üretilir. Konuşma, müzik, çevresel ses olayları ve arka plan gürültüsü gerçek dünya kayıtlarında kaçınılmaz biçimde iç içe geçer. Sesin işlenmesine yönelik geleneksel yaklaşımlar bu karmaşıklıkla ya hedef bir kaynağı (örneğin konuşmayı) öne çıkararak ya da tüm arka planı körce bastırarak başa çıkmaya çalışmıştır. Oysa kullanıcının gerçek ihtiyacı çoğu zaman bundan farklıdır: yalnızca belirli, istenmeyen bir ses sınıfını — bir klima uğultusunu, kapı zilini ya da trafik gürültüsünü — kaldırmak, geri kalan tüm sesleri ise olduğu gibi korumak.

Bu proje, söz konusu ihtiyacı sorgu-koşullu derin kaynak ayrıştırma çerçevesinde ele almaktadır. Önerilen sistemde kullanıcı, kaldırılmasını istediği ses sınıfını açıkça belirtir; sistem bu sorguyu bir öznitelik modülasyonu mekanizması olan Feature-wise Linear Modulation (FiLM) aracılığıyla U-Net mimarisine enjekte eder ve hedef sınıfa karşılık gelen bir zaman-frekans maskesi üretir. Böylece aynı ağ ağırlıkları, çalışma zamanında farklı sorgulara yanıt verebilir; bu da mimarinin desteklenen sınıf sayısından bağımsız, ölçeklenebilir bir yapıda kalmasını sağlar. Gerçek dünya kullanımını mümkün kılmak amacıyla sisteme bir algılama başlığı eklenmiş ve tüm bileşenler bir Gradio web uygulamasında birleştirilmiştir.

Çalışmanın bir diğer temel özelliği, tek bir nihai modelin sunulmasından çok, sistemin v1.0'dan v2.8'e uzanan iteratif mühendislik sürecinin belgelenmesidir. Her geliştirme adımında karşılaşılan başarısızlık modları, kök-neden analiziyle incelenmiş ve sonraki sürümün tasarım kararlarını doğrudan yönlendirmiştir. Bu yaklaşım; eğitim çöküşünün nasıl giderildiğini, veri kümesi seçiminin neden sınırlı tutulduğunu ve algılama başarımının hangi adımlarla iyileştirildiğini somut biçimde ortaya koymaktadır. Aşağıdaki bölümler, önce problemin ve motivasyonun ayrıntılı bir tanımını sunmakta, ardından zorlukları, projenin katkılarını ve çalışmanın organizasyonunu ele almaktadır.

1.1. Problem Tanımı ve Motivasyon

Gündelik ses ortamları nadiren tek bir ses kaynağından oluşur. Bir video konferans kaydında konuşmanın arkasında bir klima uğultusu, bir köpek havlaması veya bir siren sesi bulunabilir; bir saha kaydında istenen doğa sesleri trafik gürültüsüyle örtüşebilir.

Klasik gürültü engelleme (noise cancelling) yaklaşımları, tipik olarak ya tüm arka planı bastıran genel amaçlı gürültü azaltma filtreleri ya da yalnızca konuşmayı koruyan konuşma-merkezli sistemlerdir. Bu yaklaşımların ortak kısıtı, neyin bastırılacağı konusunda kullanıcıya seçim hakkı tanımamalarıdır.

Bu projede ele alınan problem, seçici gürültü engelleme (selective noise cancelling) olarak adlandırılmaktadır: kullanıcı, bir karışım içerisindeki hangi ses sınıf(lar)ının kaldırılacağını açıkça belirtir ve sistem yalnızca bu sınıf(lar)ı bastırarak geri kalan içeriği korur. Örneğin kullanıcı, bir kaydın içindeki yalnızca “klima” ve “siren” seslerini kaldırmayı, fakat konuşmayı ve müziği korumayı seçebilir. Bu, sabit bir kaynak kümesi için ayrı ayrı maske üreten klasik ayrıştırma ağlarından farklı olarak, modelin çalışma zamanında hangi kaynağı hedefleyeceğinin söylenebildiği bir sorgu-koşullu (query-conditioned) formülasyon gerektirir.

1.2. Seçici Gürültü Engellemenin Zorlukları

Seçici gürültü engelleme problemi birkaç açıdan zorludur:

1. Ölçeklenebilirlik. Her ses sınıfı için ayrı bir çıkış başlığı tasarlamak, sınıf sayısı arttıkça (ESC-50 için 50, FSD50K dahil edildiğinde 200’ün üzerinde) sürdürülemez hale gelir. Mimarının sınıf sayısından bağımsız olması gerekir.
2. Koşullandırma. Modelin, hangi sınıfı ayrıştıracağı bilgisini etkili biçimde kullanması gerekir. Bu bilgiyi yalnızca son katmana eklemek genellikle yetersizdir; koşullandırmanın özniteliklerin oluşumuna derinlemesine nüfuz etmesi beklenir.
3. Algılama (detection). Kullanıcıya hangi sınıfların kaldırılabilceğini sunabilmek için, sistemin bir kayıttaki mevcut sınıfları güvenilir biçimde tespit etmesi gerekir. Yanlış pozitifler (var olmayan bir sınıfın listelenmesi) kullanıcı deneyimini bozar.
4. Değerlendirme. Ayrıştırma kalitesini ölçen metrikler (ör. SI-SDR) ile algılama kalitesini ölçen metrikler (precision/recall/F1) farklı yönlerde optimuma işaret edebilir; ikisi arasında bir denge kurulması gerekir.
5. Veri kümesi gürültüsü. Çok-etiketli ve uzun-kuyruklu veri kümeleri (ör. FSD50K), yerel olarak doğrulanamayan sınıflar nedeniyle sistematik yanlış pozitiflere yol açabilir.

1.3. Projenin Katkıları

Bu projenin başlıca katkıları şunlardır:

- Sınıf sayısından bağımsız, FiLM-koşullu bir U-Net mimarisi ile seçici gürültü engelleme için uçtan uca bir sistem (algılama → maske üretimi → yeniden sentez → video remux) tasarlanmıştır.
- Anlık karışım üretimi yapan, negatif örnekler ve ağırlıklı zor-negatif (weighted hard-negative) örnekleme ile algılama başarımını iyileştiren bir veri üretici (SeparationMixer) geliştirilmiştir.
- Ayırıştırma gövdesini değiştirmeden eklenebilen, FiLM-koşullu darboğaz üzerinden çalışan hafif bir algılama başlığı önerilmiş ve sezgisel (heuristic) maske-enerjisi tabanlı algılama ile karşılaştırılmıştır.
- v1.0'dan v2.8'e uzanan on sürümlük iteratif geliştirme süreci, her sürümün başarısızlık modları kök-neden analiziyle birlikte sistematik olarak belgelenmiştir. Bu, literatürde sıklıkla yalnızca nihai modelin raporlandığı çalışmalardan farklı olarak, mühendislik sürecinin kendisini bir katkı olarak sunar.
- Tüm sürümler aynı protokolle (SI-SDRi ve algılama F1) ölçülmüş; sonuçlar yayın kalitesinde karşılaştırmalı şekillere ve çok-sayfalı bir Excel çalışma kitabına dönüştürülmüştür.

1.4. Proje Raporunun Organizasyonu

Projenin kalan bölümleri şu şekilde düzenlenmiştir. Bölüm 2, ses kaynak ayırıştırma, U-Net, FiLM, sorgu-koşullu ayırıştırma, değerlendirme metrikleri ve kullanılan veri kümeleri hakkındaki kuramsal altyapıyı ve ilgili çalışmaları sunar. Bölüm 3, önerilen sistemin yöntemini — spektrogram sözleşmesi, karışım üretici, mimari, kayıp fonksiyonları, eğitim ve çıkarım hattı — ayrıntılandırır. Bölüm 4, çalışmanın merkezini oluşturan v1.0–v2.8 iteratif geliştirme sürecini her sürümün gerekçesi ve sonuçlarıyla anlatır. Bölüm 5, ölçülen nicel sonuçları karşılaştırmalı olarak sunar. Bölüm 6, bulguları tartışır; Bölüm 7, gelecek çalışmaları özetler ve Bölüm 8 projeyi sonuçlandırır.

2. TEKNİK ARKA PLAN ve İLGİLİ ÇALIŞMALAR

2.1. Ses Kaynak Ayırıştırma

Ses kaynak ayırıştırma (sound source separation), birden çok ses kaynağının karışımından tekil kaynakları geri kazanma problemidir. Problem, kör kaynak ayırıştırma (blind source separation) ve denetimli (supervised) ayırıştırma olmak üzere geniş iki sınıfa ayrılır. Bu proje, hedef kaynağın sınıfının bilindiği denetimli ve koşullu bir formülasyonu benimser.

2.1.1. Klasik Yaklaşımlar

Derin öğrenme öncesi dönemde ayırıştırma, büyük ölçüde hesaplamalı işitsel sahne analizi (Computational Auditory Scene Analysis, CASA) ve negatif-olmayan matris ayırıştırması (Non-negative Matrix Factorization, NMF) gibi yöntemlerle ele alınmıştır. Bu yöntemler, kaynakların spektral yapıları hakkında güçlü varsayımlar gerektirir ve çok sayıda sınıfa ölçeklenmekte zorlanır.

2.1.2. Derin Öğrenme Tabanlı Ayırıştırma

Derin öğrenmenin yükselişiyle birlikte, ayırıştırma büyük ölçüde bir denetimli regresyon problemi olarak yeniden formüle edilmiştir. Hershey ve ark. [1] tarafından önerilen Deep Clustering, zaman-frekans birimlerini ayrıştırılabilir bir gömme uzayına eşleyerek konuşmacı-bağımsız ayırıştırmayı mümkün kılmıştır. Luo ve Mesgarani'nin Conv-TasNet [2] çalışması, ayırıştırmayı doğrudan zaman alanında öğrenilen bir filtre bankası üzerinden gerçekleştirerek ideal zaman-frekans maskelemenin üzerine çıkmıştır. Müzik alanında, Jansson ve ark. [3] U-Net mimarisini şarkıcı sesi ayırıştırmaya uyarlamış; Stoller ve ark. [4] bunu zaman alanına taşımıştır. Wang ve Chen [5], denetimli konuşma ayırıştırmaya dair kapsamlı bir derleme sunar.

2.1.3. Zaman-Frekans Maskeleme

Spektrogram tabanlı ayırıştırmanın yaygın paradigması, karışımın kısa-zamanlı Fourier dönüşümü (Short-Time Fourier Transform, STFT) genliği üzerine uygulanan bir yumuşak maske (soft mask) öğrenmektir. X karışımın karmaşık STFT'si, $|X|$ genliği olmak üzere, bir kaynağın kestirimi

$$\hat{S} = M \odot |X|, \quad M \in [0, 1]^{F \times T}$$

biçiminde elde edilir; burada M ağ tarafından üretilen maske, $\odot$ eleman-bazlı çarpım, F frekans bini ve T zaman çerçevesi sayısıdır. Dalga formuna geri dönüş tipik olarak karışımın fazının yeniden kullanılmasıyla (mixture-phase reuse) yapılır; bu yaklaşımın yapısal sınırlamaları Bölüm 6’da tartışılmaktadır. Faz kestirimi başlı başına bir araştırma konusudur [6].

2.2. U-Net Mimarisi

U-Net, Ronneberger ve ark. [7] tarafından biyomedikal görüntü bölütleme için önerilen, kodlayıcı-kod çözücü (encoder-decoder) yapısında ve atlama bağlantıları (skip connections) içeren tam-evrişimsel bir mimaridir. Kodlayıcı, ardışık alt-örnekleme (downsampling) ile bağlamsal bilgiyi giderek daha soyut ölçeklerde yakalar; kod çözücü, üst-örnekleme (upsampling) ile uzamsal çözünürlüğü geri kazanır. Atlama bağlantıları, kodlayıcıdaki yüksek çözünürlüklü öznitelikleri doğrudan kod çözücüye taşıyarak ince ayrıntıların korunmasını sağlar. Bu özellik, spektrogram maskeleme için idealdir: maske, hem geniş bağlamsal yapıyı (hangi bölgeler hedef kaynağa ait) hem de ince spektral ayrıntıyı (bin düzeyinde sınırlar) gerektirir.


2.3. FiLM: Feature-wise Linear Modulation

Feature-wise Linear Modulation (FiLM), Perez ve ark. [8] tarafından görsel akıl yürütme için önerilen, bir koşullandırma girdisinin (ör. bir soru veya bir sınıf kimliği) bir sinir ağının ara öznitelik haritalarını kanal bazında ölçeklemesini ve kaydırmasını sağlayan genel bir mekanizmadır. Bir öznitelik haritası x ve koşullandırma girdisinden türetilen kanal-bazlı parametreler γ (ölçek) ve β (kaydırma) için FiLM dönüşümü

$$FiLM(x) = \gamma(q) \odot x + \beta(q)$$

biçimindedir. Burada q koşullandırma (bu çalışmada one-hot sınıf sorgusu) vektörüdür ve γ, β bu vektörden öğrenilen doğrusal izdüşümlerle elde edilir. Dumoulin ve ark. [9], FiLM’i daha geniş bir öznitelik-bazlı dönüşümler ailesi içinde inceler.

Kaynak ayrıştırma bağlamında FiLM’in en doğrudan uygulaması, Meseguer-Brocal ve Peeters’in Conditioned-U-Net [10] çalışmasıdır; bu çalışma, tek bir U-Net’in farklı kaynakları ayırtmak üzere bir kontrol mekanizmasıyla koşullandırılabilceğini göstermiştir. Bu projedeki mimari, doğrudan bu fikrin üzerine kurulur ve FiLM’i her kodlayıcı seviyesine uygulayarak koşullandırmanın öznitelik oluşumuna derinlemesine nüfuz etmesini sağlar.



Şekil 2.1: FiLM dönüşümü. Koşullandırma girdisi (sorgu gömme q), kanal-bazlı ölçek γ ve kaydırma β parametrelerini üretir; öznitelik haritası x önce γ ile çarpılır, ardından β eklenir.

2.4. Sorgu-Koşullu ve Hedef Kaynak Ayırıştırma

Sorgu-koşullu (query-conditioned) veya hedef kaynak (target source) ayırıştırma, ayırıştırılacak kaynağın çalışma zamanında bir sorgu ile belirtildiği bir paradigmadır. Konuşma alanında, Zmolikova ve ark.'nın SpeakerBeam [11] çalışması bir hedef konuşmacıyı bir referans ile çıkarır. Ochiai ve ark. [12], sınıf etiketi ile koşullanan evrensel bir ses seçici önerir; bu çalışma, bu projenin formülasyonuna kavramsal olarak en yakın çalışmalardandır. Evrensel ses ayırıştırma alanında Kavalero ve ark. [13] ve Tzinis ve ark. [14] sınıf-bilgisinin ayırıştırmaı iyileştirdiğini göstermiştir. Denetimsiz ortamlarda Wisdom ve ark.'nın MixIT [15] yöntemi karışım-değişmez eğitim önerir. Bu proje, sınıf-koşullu denetimli formülasyonu benimser ve onu pratik bir seçici-bastırma uygulamasına bağlar.

2.5. STFT ve Spektrogram Temsili

Bir $x(n)$ zaman alanı sinyalinin kısa-zamanlı Fourier dönüşümü

$$X(m, k) = \sum_n x(n) w(n - mH) e^{-j2\pi kn/N}$$

ile verilir; burada w pencere fonksiyonu, H adım büyüklüğü (hop length), N pencere/DFT boyutu, m çerçeve ve k frekans bini indeksleridir. Bu çalışmada tüm ses 16 kHz mono'ya örneklenir; $N = 512$, $H = 128$ kullanılır ve Nyquist bini atılarak $F = 256$ frekans bini elde edilir. Ağ girdisi, sayısal kararlılık için logaritmik olarak sıkıştırılmış genliktir:

$$X_{log} = \log(1 + |X|).$$

Bir U-Net çağrısı, $T = 128$ çerçeveye (≈ 1 saniye) karşılık gelir.

2.6. Değerlendirme Metrikleri

2.6.1. SI-SDR

Ölçek-değişmez sinyal-bozulma oranı (Scale-Invariant Signal-to-Distortion Ratio, SI-SDR), Le Roux ve ark. [16] tarafından, klasik SDR [17] metriğinin ölçek duyarlılığını gidermek üzere önerilmiştir. Bir $\hat{s}$ kestirimi ve s referansı için SI-SDR şu şekilde tanımlanır:

$$\alpha = \frac{\langle \hat{s}, s \rangle}{\langle s, s \rangle}, \quad SI - SDR = 10 \log_{10} \frac{\|\alpha s\|^2}{\|\hat{s} - \alpha s\|^2}.$$

Çalışmada raporlanan başlıca büyüklük, modelin kestirimi ile işlenmemiş karışım arasındaki SI-SDR farkı olan SI-SDR_i (improvement)'dir:

$$SI - SDR_i = SI - SDR(\hat{s}, s) - SI - SDR(x, s),$$

yani modelin, “hiçbir şey yapmama” (karışımı doğrudan kestirim olarak kullanma) temeline göre sağladığı iyileşmedir.

2.6.2. Precision, Recall ve F1


Algılama başarımı, sınıf-bazlı kesinlik (precision, P), duyarlılık (recall, R) ve bunların harmonik ortalaması olan F1 ile ölçülür:

$$P = \frac{TP}{TP+FP}, \quad R = \frac{TP}{TP+FN}, \quad F1 = \frac{2PR}{P+R}.$$

Burada TP , FP ve FN sırasıyla doğru pozitif, yanlış pozitif ve yanlış negatif sayılarıdır. Raporlanan ana büyüklük, sınıflar üzerinden ortalanan makro-F1'dir.

2.7. Veri Kümeleri

ESC-50 [18], 50 çevresel ses sınıfından her biri için 40 klip içeren, dengeli ve yaygın kullanılan bir ölçüttür. UrbanSound8K [19], 10 kentsel ses sınıfından oluşur; sınıf başına yüzlerce klip içerir ve bu çalışmada ESC-50 ile birleştirilir (dört sınıf takma-ad eşlemesiyle ESC-50'ye katılır, altı sınıf yenidir). FSD50K [20], AudioSet ontolojisine dayalı, insan-etiketli, çok-etiketli ve uzun-kuyruklu büyük bir veri kümesidir; çalışmanın bir döneminde (v2.3–v2.6) dahil edilmiş, ancak yerel olarak doğrulanamayan sınıfların sistematik yanlış pozitiflere yol açması nedeniyle v2.8'de tamamen çıkarılmıştır (bkz. Bölüm 4.5-4.10).




Şekil 2.2: Kullanılan veri kümeleri ve birleşik kelime dağarcığı. ESC-50 ve UrbanSound8K çekirdek 56-sınıflı dağarcığı oluşturur; FSD50K bir dönem (v2.3–v2.6) dahil edilmiş, hayalet yanlış-pozitifler nedeniyle v2.8’de çıkarılmıştır.

3. Yöntem

3.1. Sistem Genel Bakışı

Önerilen sistem, uçtan uca dört aşamadan oluşur: (i) yüklenen ses/videodaki mevcut sınıfların algılanması, (ii) kullanıcı tarafından kaldırılmak üzere seçilen sınıflar için maske üretimi, (iii) maskeden hedef kaynağın çıkarılması ve karışımdan bastırılması, (iv) temizlenmiş sesin (ve varsa videonun) yeniden sentezlenip birleştirilmesi (remux). Uçtan uca veri akışı Şekil 3.1’de özetlenmiştir:



Şekil 3.1 : Uçtan uca sistem hattı (pipeline): ham ses kümelerinden web uygulamasındaki çıkarıma kadar veri akışı.

3.2. Spektrogram Sözleşmesi

Tüm ses, 16 kHz mono'ya örneklenir. STFT parametreleri Tablo 3.1'de verilmiştir. Nyquist bini atılır, böylece U-Net girdisi ($F = 256, T = 128, 1$) boyutunda logaritmik genlik spektrogramı olur. Bu sözleşme, eğitim, değerlendirme ve web uygulaması arasında ortaktır; çıkarımda örtüşme-toplama (overlap-add) ile uzun kayıtlar 1 saniyelik pencerelere bölünerek işlenir.

Tablo 3.1 : Spektrogram sözleşmesi parametreleri

Parametre	Değer
Örnekleme hızı	16 000 Hz (mono)
Pencere boyutu N (n_fft)	512
Adım H (hop_length)	128
Frekans bini F	256 (Nyquist bini atılır)
Zaman çerçevesi T	128 (≈ 1 s)
Girdi temsili	$\log(1 + X)$


3.3. Anlık Karışım Üretici (SeparationMixer)

Karışım üretiminin akışı Şekil 3.2'de özetlenmiştir. Eğitim verisi, sabit bir dosyadan okunmaz; her adımda SeparationMixer tarafından bellek-ıç i klip ön belleğinden anlık olarak üretilir. Böylece sınıf sayısı sınırsız kalır ve veri çeşitliliğ i etkin biçimde sonsuzdur. Her örnek, bir (*karş m, sorgu, hedef stem*) üç lüsüdür:

- Karışım. 1 ile max_mix (varsayılan 4) arasında rastgele sayıda klip, amp_range aralığ ından çekilen genliklerle toplanır.
- Arka plan gürültüsü artırması. bg_noise_prob olasılığ ıyla, karış ıma bg_snr_db_range aralığ ından bir SNR ile beyaz veya pembe gürültü eklenir; hedef stem bozulmaz, böylece model gürültüyü yok saymayı öğrenir.
- Tepe normalizasyonu. Karışım, zaman alanında tepe genliğ i 1.0 olacak şekilde normalize edilir; aynı ölçek hedef stem'e de uygulanır. Bu, eğitim ve çıkarım dağ ılımlarının eşleşmesi için kritiktir (bkz. v2.0 başarısızlığ ı, Bölüm 4.2).
- Negatif örnekler. negative_prob olasılığ ıyla, sorgu karış ımda bulunmayan bir sınıfı sorar ve hedef sessizliktir. Bu negatif örnekler, modelin var olmayan sınıflar için sıfıra yakın maske üretmesini öğretir.
- Ağırlıklı zor-negatif örnekleme. over_firing_classes listesindeki sınıflar, negatif örneklerde over_firing_weight kat daha sık hedef olarak seçilir; bu, yaygın yanlış-pozitif üreten geniş-bantlı sınıfların (siren, thunderstorm vb.)

bastırılmasını güçlendirir.

- Sınıf dışlama. `exclude_classes` listesindeki sınıflar, önbellekten tamamen kaldırılır; böylece ne sorgulanabilir ne de hedef olabilirler.



Şekil 3.2 : *SeparationMixer* bir eğitim örneğini nasıl üretir. Klip seçimi, toplama, gürültü artırma ve normalizasyondan sonra `negative_prob` olasılığıyla negatif (hedef sessizlik) ya da pozitif (hedef stem) bir örnek olarak dallanır.

3.4. FiLM-Koşullu U-Net Mimarisi

3.4.1. Kodlayıcı, Darboğaz ve Kod Çözücü

Mimarinin tümü Şekil 3.4’de gösterilmiştir. Ağ, iki girdi alır: logaritmik genlik spektrogramı 256,128,1 ve one-hot sınıf sorgusu `num_classes`. Sorgu, paylaşılan bir gömme (embedding) katmanı ile 128 boyutlu bir vektöre izdüşürülür ve her FiLM katmanı bu gömmeden kendi / izdüşümünü hesaplar. Kodlayıcı, `base_filters=32` ile başlar ve her seviyede kanal sayısını iki katına çıkarır (32, 64, 128, 256, darboğazda 512). Her seviye, iki adet 33 evrişim + toplu normalleştirme (Batch Normalization [21]) + ReLU içeren standart bir çift-evrişim bloğundan oluşur.

3.4.2. Her Seviyede FiLM Koşullandırması

Mimarinin ayırt edici tasarım kararı, FiLM’in yalnızca darboğaza değil, her kodlayıcı

seviyesine (e1–e4 ve darboğaz) uygulanmasıdır. Böylece kod çözücüye giren atlama bağlantıları zaten sınıfa-özümlü özellikler taşıyor ve maske kesinliği artıyor. Bu karar, v2.2’de tanıtılmış ve sonraki tüm sürümlerde korunmuştur (bkz. Bölüm 4.4).

3.4.3. Çıkış Maskesi

Kod çözücünün son katmanı, 1×1 evrişim ve sigmoid aktivasyonla $[0, 1]$ aralığında bir yumuşak maske (256, 128, 1) üretir. Karışık-duyarlılık (mixed precision) altında bu çıkış, sayısal kararlılık için float32’ye sabitlenir.


3.4.4. Algılama Başlığı

v2.6’dan itibaren, FiLM-kışullu darboğaz üzerine hafif bir algılama başlığı (Şekil 3.3) eklenmiştir (bkz. Bölüm 4.8):



Şekil 3.3 : FiLM-kışullu darboğaz üzerine eklenen algılama başlığı (v2.6 ve sonrası). Darboğaz zaten sorguya kışullu olduğundan küresel ortalama havuzlama sınıf-bilinçli bir vektör üretir; son sigmoid, sorgulanan sınıfın mevcudiyet olasılığını verir.

Darboğaz zaten sorguya kışullu olduğundan, küresel ortalama havuzlama onu sınıf-bilinçli bir vektöre indirger ve son sigmoid, $P(\text{sorgulanan snf mevcut}|\text{karşm})$ olasılığını kestirir.



Şekil 3.4 : FiLM-koşullu U-Net mimarisi. Kodlayıcı (mavi) her seviyede FiLM ile sorguya koşullanır; atlama bağlantıları (kesikli) sınıfa-özel özellikleri kod çözümüye (yeşil) taşır. Sorgu gömmesinden türetilen FiLM (γ, β) parametreleri bütün kodlayıcı seviyelerine ve darboğaza enjekte edilir. Darboğazdan dallanan algılama başlığı (mor) sorgulanan sınıfın mevcudiyetini kestirir.

3.4.5. Eğitim Sarmalayıcısı

Standart bir `model.fit` çağrısının çalışması için ağı, maskenin lineer genlikle çarpımını graf içinde yapan bir `Multiply` katmanı ile sarmalanır. Böylece kaydedilen .h5 dosyası üç girdiye (`[log_mag, class_query, linear_mag]`) ve (algılama başlığı varsa) iki çıktıya (`[est_stem, class_presence]`) sahip olur; `Lambda` katmanı kullanılmadığından özel nesneler olmadan yeniden yüklenebilir.

3.5. Kayıp Fonksiyonları

3.5.1. Çok-Çözünürlüklü L1 (Ayrıştırma)

Ayrıştırma kaybı, kestirilen ve gerçek stem genlikleri arasındaki, tam + yarım + çeyrek çözünürlükte hesaplanan L1 farklarının ağırlıklı toplamıdır:

$$L_{sep} = \sum_{i=0}^2 (0.5)^i \| P_i(S) - P_i(\hat{S}) \|_1,$$

burada P_i , i kez 2×2 ortalama havuzlama uygulayan operatördür. Daha kaba ölçekler, ince ayrıntı optimize edilmeden önce genel spektral şeklin oturmasına yardımcı olur.

3.5.2. İkili Çapraz Entropi (Algılama)

Algılama başlığı, y gerçek varlık etiketi (1 mevcut, 0 yok) ve p kestirilen olasılık için ikili çapraz entropi (Binary Cross-Entropy, BCE) ile eğitilir:

$$L_{det}^{BCE} = - [y \log p + (1 - y) \log(1 - p)].$$

Varlık etiketi, hedef stem genliğinden otomatik türetilir: $y = 1[\max|S| > 10^{-6}]$.

3.5.3. Focal Loss ve Gradyan Çöküşü

v2.7’de, sınıf dengesizliğini ele almak amacıyla focal loss [22] denenmiştir:

$$L_{det}^{focal} = - \alpha_t (1 - p_t)^\gamma \log(p_t),$$

$\alpha = 0.25$, $\gamma = 2$ ile. Ancak rastgele başlangıçta ($p \approx 0.5$) çarpan $\alpha_t (1 - p_t)^\gamma = 0.25 \times 0.5^2 = 0.0625$ olup, BCE’nin başlangıç değeri $-\log(0.5) \approx 0.693$ ’e kıyasla yaklaşık 10 kat küçüktür. Bu, başlığın gradyanını başlangıçtan itibaren açlığa sürükleyerek çöküşe yol açmıştır (bkz. Bölüm 4.9). Bu nedenle v2.8’de BCE’ye geri dönmüştür.

3.5.4. Bileşik Kayıp

Algılama başlıklı modelin toplam kaybı,

$$L = L_{sep} + \lambda_{det} L_{det},$$

biçimindedir; burada λ_{det} (detection_loss_weight) v2.6’da 0.3, v2.8’de 0.5 olarak ayarlanmıştır.

3.6. Eğitim Prosedürü

Eğitim, Adam [23] optimleyicisi (=10⁻³) ile yürütülür. Eğitim kümesi sonsuz bir tf.data akışıdır; val_loss’un kararlı olması için sabit bir doğrulama kümesi bir kez maddeleştirilir. Geri çağırımlar (callbacks): en iyi ağırlıkları geri yükleyen erken durdurma (EarlyStopping), en iyi val_loss’u kaydeden ModelCheckpoint ve plato üzerinde öğrenme oranını yarıya indiren ReduceLROnPlateau. Girdi hattı, GPU’yu aç bırakmamak için birden çok bağımsız karıştırıcıyı paylaşılan bir klip önbellegi üzerinde çoklu-iş parçacığıyla serpiştirir (interleave). Karışık-duyarlık ve XLA (jit_compile) desteklenir.

3.7. Çıkarım Hattı

3.7.1. Algılama

detect_sounds, girdinin ilk birkaç saniyesinde her sınıf için U-Net'i çalıştırır. Algılama başlığı varsa, doğrudan class_presence sigmoid olasılığı skor olarak kullanılır. Aksi halde (eski, yalnızca-maske modeller) sezgisel skor $energy_ratio \times (1 + CoV^2)$ kullanılır; burada CoV, maskenin değişim katsayısıdır (özgüllük göstergesi). Skoru bir mutlak taban ve göreceli bir eşikğin üzerinde olan sınıflar yüzeye çıkarılır.

3.7.2. Bastırma

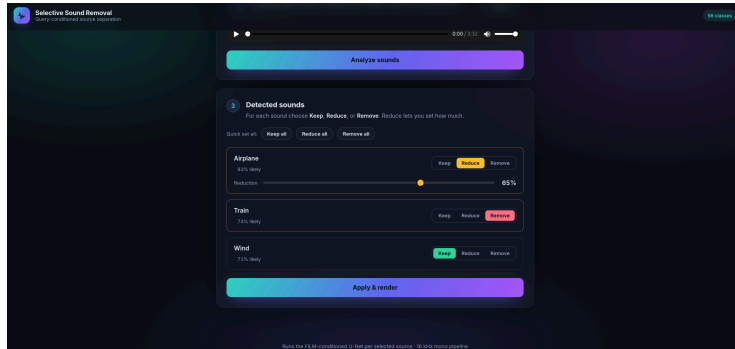
remove_sounds, tüm dosyanın tek bir STFT'sini hesaplar; TIME_FRAMES çerçevelik her parça için (%50 örtüşme) seçilen her sınıfa U-Net'i çalıştırır, çarpımsal güç-oranı maskelerini birleştirir:

$$M = clip\left(1 - strength \cdot \frac{s^2}{x^2}, 0, 1\right),$$

maskeyi zaman boyunca yumuşatır, Hanning-ağırlıklı örtüşme-toplama uygular ve özgün fazla tek bir ISTFT ile dalga formuna döner. Video yüklemeleri için temizlenmiş ses, ffmpeg ile özgün video parçasının üzerine yeniden bindirilir (remux).

3.8. Web Uygulaması

Sistem, bir Gradio web uygulaması ile uçtan uca sürülür: ses/video yükle mevcut sınıfları algıla kaldırılacakları işaretlerle temizlenmiş çıktıyı (ses ve varsa video) işle. İki uygulama cephesi (klasik webapp.py ve modern modern_web/) aynı algılama eşik mantığını paylaşacak biçimde hizalanmıştır.



Şekil 3.5 : Web uygulaması arayüzü ekran görüntüsü.

4. İteratif Geliştirme Süreci (v1.0–v2.8)

Bu bölüm, projenin merkezini oluşturur. Her sürüm; gerekçesi, yapılan değişiklik, gözlemlenen sonuç ve (varsa) başarısızlık modunun kök-neden analizi ile sunulur. Tüm sürümlerin üst düzey özeti Tablo 4.1’de verilmiştir.

Tablo 4.1 : Sürümlerin üst düzey özeti. (F1 ve SI-SDRi değerleri ilgili sürüm bölümlerinde açıklanan ölçüm koşullarına aittir.)

Sürüm	Ana değişiklik	Durum	Ölçülen sonuç
v1.0	İlk çalışan FiLM U-Net (ESC-50)	Çalışıyor	—
v2.0	Agresif artırma	Bozuk	Çöküş
v2.1	Artırma düzeltildi, normalizasyon	Kısmi	SI-SDRi — 22. 18; F1 0. 21
v2.2	Tam-kodlayıcı FiLM + MRL1	Kısmi	SI-SDRi — 22. 79; F1 0. 13
v2.3	negative_prob↓; FSD50K	Kısmi	SI-SDRi — 21. 49; F1 0. 02
v2.4	Min-klip tabanı + allow-list	Kısmi	SI-SDRi — 20. 05; F1 0. 09
v2.5	Zor-negatif (geçersiz dosya)	Geçersiz	—
v2.6	Algılama başlığı	Eğitildi	SI-SDRi — 15. 73; F1 0. 17
v2.7	Focal loss	Bozuk	Başlık çöktü
v2.8	BCE + FSD50K çıkarıldı	Eğitildi	SI-SDRi — 24. 85; F1 0. 32

4.1. v1.0 — İlk Çalışan Temel Model

v1.0, FiLM-koşullu U-Net mimarisini ve anlık karıştırma hattını kurmuştur. Yalnızca ESC-50 (50 sınıf) üzerinde, negative_prob=0.25 ve artırma olmadan eğitilmiştir. Bu

aşamada hem algılama hem de bastırma işlevsel olarak çalışmaktadır. Bu sürüm, sonraki tüm çalışmanın temel referans noktasıdır.

4.2. v2.0 — Agresif Artırmanın Yol Açtığı Eğitim Çöküşü

v2.0, UrbanSound8K eklenerek (≈ 56 sınıf) ve agresif artırma ile eğitilmiştir; ancak tamamen başarısız olmuştur. Üç birleşik neden tespit edilmiştir:

1. `negative_prob=0.45` çok yüksek. %45 negatif oranında L1 kaybı, her şey için sifıra-yakın çıktı üretmeyi güçlü biçimde ödüllendirir; model, pozitif örnekleri hiç öğrenmeden “güvenli sessiz çıktı” dengesine yerleşir.
2. `bg_snr_db_range=(5, 20)` dB çok agresif. 5 dB SNR’de gürültü, hedef sinyalin %56’sı kadardır; denetim sinyali bu denli gürültüye gömülünce model ayrıştırmayı öğrenemez.
3. Çıkarımda ölçek uyuşmazlığı. Eğitim her zaman tepe-normalizasyonu yaparken, web uygulaması ham (normalize edilmemiş) ses besliyordu; bu, eğitilmemiş bir aktivasyon rejimine yol açtı.

Belirtiler: net sesler için bile 0–2 alakasız sınıf algılanması ve hiçbir sınıfta duyulabilir bastırma olmaması. Bu başarısızlık, sonraki sürümlerin normalizasyon ve artırma disiplini belirlemiştir.

4.3. v2.1 — Artırmanın Düzeltilmesi ve Çıkarım Normalizasyonu

v2.1, v2.0’ın üç nedenini de gidermiştir: `negative_prob` 0.30’a, `bg_noise_prob` 0.10’a düşürülmüş, `bg_snr_db_range` (15, 30) dB’ye yükseltilmiş ve çıkarımda tam-dosya tepe normalizasyonu eklenmiştir. Ölçülen sonuçlar: SI-SDRi ortalama -22.18 dB, algılama makro-F1 0.21, FP:TP oranı 5.5:1. Tanılama (diagnose) genel olarak SAĞLIKLI; FiLM koşullandırması çalışıyor. İki başarısız sınıf: `cat` ve `chirping_birds`. Dinleme testlerinde ses kalitesi v2.0’a göre iyileşmiş; iki sorun saptanmıştır: (i) 0.25 s aralıklı örtüşme-toplama nabız artefaktı, (ii) fazla sayıda alakasız sınıf algılanması — her ikisi de v2.2’de ele alınmıştır.

4.4. v2.2 — Tam-Kodlayıcı FiLM, Çok-Çözünürlüklü Kayıp ve Sıkı Algılama

v2.2, üç değişiklik getirmiştir: (i) FiLM artık her kodlayıcı seviyesine uygulanır (yalnızca darboğaz yerine), (ii) çok-çözünürlüklü L1 kaybı (Denklemler [eq:mr1]) eklenir, (iii) çıkarımda örtüşme %50’den %75’e çıkarılır ve algılama skoru $1+CoV2$ ile keskinleştirilir. Ölçülen sonuçlar: SI-SDRi -22.79 dB, makro-F1 0.13. Nabız artefaktı

düzelmiştir. Ancak bu sürümde FSD50K, tek-etiket filtre hatası nedeniyle 0 klip yüklediğinden mimari değişikliklerin net etkisi ölçülemedi; bastırma strength=1.0'da fazla nazik kalmıştır. Kök neden: negative_prob=0.30 modeli aşırı muhafazakâr maskelere itmektedir.

4.5. v2.3 — negative_prob Düşürme ve FSD50K'nın Dahil Edilmesi

v2.3, negative_prob'u 0.15'e düşürmüş ve (filtre hatası düzeltildiği için) FSD50K'yı doğru biçimde yüklemiştir; toplam model kelime dağarcığı 235 sınıfa ulaşmıştır. Ölçülen sonuçlar: SI-SDRi -21.49 dB (marjinal iyileşme), fakat makro-F1 0.02'ye çökmüştür (TP/FP/FN =13/1092/475). Kök neden: yerel sesi olmayan 179 FSD50K-yalnız sınıf, gerçek karışımlarda asla bulunamadığından yalnızca yanlış pozitif üretebilir. purr, bass_guitar, ringtone gibi sınıflar içerikten bağımsız olarak her seste tetiklenmiştir. Bu, "bass_guitar her dosyada görünüyor" gözlemdir ve sonraki üç sürümün ana mücadele konusunu oluşturur.

4.6. v2.4 — Minimum Klip Tabanı ve Allow-List

v2.4, FSD50K uzun-kuyruğunu budamak için sınıf başına minimum 40 klip tabanı (min_clips_per_class) eklemiştir; taban birleştirme sonrası uygulanır, böylece çapraz-veri kümesi takma adları havuzlanır. Ölçülen sonuçlar: SI-SDRi -20.05 dB (en iyi negatif değer); ham makro-F1 0.05, allow-list ile 0.09. Bir eşik taraması (Tablo) sonucunda webapp ve değerlendirme için varsayılan cap=0.80, top_k=5 seçilmiştir. siren, thunderstorm, clock_alarm her eşik düzeyinde kalıcı yanlış pozitif üretmiştir; bu, eşik ayarıyla çözilemeyen yapısal bir sorundur ve v2.5'in ağırlıklı zor-negatif eğitim fikrini doğurmuştur.

Tablo 4.2 : v2.4 algılama eşik taraması (captop_k).

relative_cap	top_k	Makro			
		F1	TP	FP	FN
0.65	10	0.11	~150	~900	~370
0.80	5	0.08	~80	~450	~420
0.90	5	0.04	~40	~150	~460

4.7. v2.5 — Ağırlıklı Zor-Negatif Eğitim (Geçersiz Dosya)

v2.5, geniş-bantlı aşırı-tetikleyen sınıflar için ağırlıklı zor-negatif örnekleme tasarımı getirmiştir: negatif örnek çekilirken siren, thunderstorm, clock_alarm gibi sınıflar 2–3

kat daha sık hedef seçilir; böylece model “bu sınıf yokken maske sıfıra yakın olmalı” kuralını öğrenir. Ancak Drive’a kaydedilen dosya, ağırlıklı zor-negatif kodu işlenmeden önceki bir koşuya aittir; checkpoint v2.4 yapılandırmasıyla üretilmiş fakat v2.5 olarak adlandırılmıştır. Bu nedenle geçersizdir ve v2.6 ile değiştirilmiştir. Tasarım fikri ise korunmuş ve sonraki sürümlerde uygulanmıştır.

4.8. v2.6 — Algılama Başlığı

v2.6, iki yapısal sorunu birlikte ele almıştır. Birincisi, maske enerjisini sınıf-varlığı için vekil olarak kullanmanın mimari olarak yanlış olduğudur; geniş-bantlı sınıflar her karışımda yüksek-enerjili difüz maskeler ürettiğinden sezgisel skor güvenilmezdir. Çözüm, FiLM-koşullu darboğazdan dallanan bir algılama başlığıdır (GlobalAveragePooling2D + Dense(128) + Dense(1, sigmoid)); çıkarımda artık doğrudan bu başlığın sigmoid olasılığı kullanılır. İkincisi, zor-negatif listesi 3’ten 10 sınıfa genişletilmiştir. Ölçülen sonuçlar: mimari değişiklik kararlı biçimde eğitilmiş, final val_loss=0.4612; algılama makro-F1 0.17’ye yükselmiştir. Ancak F1 eşik taramasında düz kalmıştır; bu, eşğin değil, modelin öğrendiği gürültülü varlık skorunun darboğaz olduğunu gösterir. Ayrıca eski (bayat) bir allow-list dosyası, 227 sınıfı içerdiğinden hayalet FP’leri şişirmiştir; bu, değerlendirme zamanında allow-list’in yerel sınıflarla kesiştirilmesiyle savunmaya alınmıştır.

Tablo 4.3 : v2.6 algılama eşik taraması (aynı checkpoint, 200 sentetik karışım).

Küme	floor	cap	top_k	Makro F1	TP	FP	FN
moderate	0.30	0.90	4	0.17	82	714	409
strict	0.50	0.95	3	0.16	77	509	419
strict2	0.70	0.95	2	0.15	57	339	430

4.9. v2.7 — Focal Loss ve Gradyan Çöküşü

v2.7, negative_prob’u 0.50’ye çıkarmış, algılama başlığını büyütmüş (Dense(256) + Dropout(0.3)) ve algılama kaybını focal loss’a çevirmiştir. Focal loss, rastgele başlangıçta gradyanı 10 kat zayıflatarak (Denklem [eq:focal] ve Bölüm 3.5 analizine bkz.) başlığı çökertmiştir: eğitim 2. epokta erken durmuş, başlık tüm girdiler için 0.5 üretmeye yakınsamıştır. Korunanlar: negative_prob=0.50 (doğru yön), yenilenen zor-negatif liste, paylaşılan-önbellekli paralel veri üreteçleri. Geri alınanlar: focal loss

yerine BCE, başlık boyutu 128'e geri.

4.10. v2.8 — BCE Algılama Kaybı ve FSD50K'nın Çıkarılması

v2.8, iki yapısal sorunu birlikte çözmüştür. (i) Focal loss yerine, başlığa ilk epoktan itibaren gerekli gradyanı sağlayan BCE (ağırlık 0.5) kullanılmıştır. (ii) FSD50K tamamen çıkarılmıştır; böylece başlık, her negatif gerçek bir negatif olan temiz ve tümüyle doğrulanabilir bir 56-sınıflı kelime dağarcığı üzerinde eğitilmiştir. Eğitim: 60 epok, erken durma tetiklenmemiş (model son epokta hâlâ iyileşiyordu); 48. epokta öğrenme oranı yarılanarak ikinci bir iniş fazı oluşmuştur. Ayırıştırma L1'i $0.4758 \rightarrow 0.2821$ (– 41%), algılama BCE'si $0.6756 \rightarrow 0.4439$ (– 34%) düşmüştür. Ölçülen sonuçlar: SI-SDRi – 24.85 dB (tümü negatif), algılama makro-F1 0.32 (v2.6'ya göre + 88%). En iyi sınıflar: vacuum_cleaner (F1=0.82), toilet_flush (0.75), crying_baby (0.63). En çok FP üreten sınıflar: footsteps (35), siren (23), fireworks (22). Kilit bulgu: FSD50K'nın çıkarılması ve BCE düzeltilmesi, hayalet-FP sorununu yapısal olarak ortadan kaldırmıştır; v2.8'deki her FP, kelime dağarcığında var olan bir sınıfta gerçek bir model hatasıdır — yani tanımlanabilir ve düzeltilebilir.

Tablo 4.4 : v2.8 eğitim sırasında kayıp bileşenlerinin değişimi.

Bileşen	Epok 1	Epok 60	Değişim
val_apply_mask_loss (ayırıştırma L1)	0.4758	0.2821	– 41%
val_._det_loss (BCE algılama)	0.6756	0.4439	– 34%


5. Sonuçlar ve Değerlendirme

Bu bölümdeki tüm karşılaştırmalı şekiller, notebooks/colab_thesis_results.ipynb defteri tarafından üretilir. Defter, listelenen her sürümü aynı protokolle ölçer (SI-SDR için 800, algılama için 200 sentetik karışım), algılamayı iki biçimde hesaplar — tam kelime dağarcığı (allowed=None) ve yerel-sınıf allow-list — ve sonuçları thesis_results/ altında PNG/PDF şekiller ile bir Excel çalışma kitabına yazar.

5.1. Versiyonlar Arası Karşılaştırma


Algılama makro-F1'inin sürümler arası gelişimi Şekil 5.1'de gösterilmektedir. Eğri,

alışmanın iki dnm noktasını aıka ortaya koyar: v2.3'teki keskin dřř (0,02) 227-sınıflı FSD50K checkpoint'inin dediėi hayalet yanlış-pozitif cezasıdır; v2.6 ile gelen toparlanma algılama bařlıėının, v2.8'deki en yksek deėer (0,32) ise BCE kaybına dnř ve FSD50K'nın tamamen kaldırılmasının sonucudur.




řekil 5.1 : Srmler arası algılama makro-F1 geliřimi. v2.3'teki kř (0,02) FSD50K hayalet yanlış-pozitiflerinden, v2.6'daki sırama algılama bařlıėının eklenmesinden, v2.8'deki en yksek deėer (0,32) BCE kaybına geiř ve FSD50K'nın kaldırılmasından kaynaklanır.

Toplam yanlış pozitif sayısının srmler arası geliřimi (řekil 5.2), hayalet-FP hacminin nasıl eritildiėini doėrudan grselleřtirir.



Şekil 5.2 : Sürümler arası toplam yanlış pozitif (FP) sayısı. v2.3'ten v2.8'e kadar FP hacmi 1092'den 456'ya gerilemiştir; en büyük düşüş, FSD50K'nın tamamen kaldırıldığı v2.8'de gerçekleşir.

Ayrıştırma SI-SDRi'sinin sürümler arası gelişimi ise Şekil 5.3'de sunulur.



Şekil 5.3 : Sürümler arası ortalama SI-SDRi (dB). Metrik tüm sürümlerde negatiftir; bu, spektrogram-faz yeniden kullanımının yapısal bir sınırlamasıdır. v2.6'nın görece yüksek değeri, hedefin baskın olduğu FSD50K örneklerinin sayısal yanlışlığından kaynaklanır.

5.2. SI-SDR Analizi

Tüm sürümlerde SI-SDRi negatiftir; yani model, izole-stem dalga-formu yeniden

kurgulamada “hiçbir şey yapmama” temelinin altında kalmaktadır. Bunun başlıca nedeni, spektrogram-faz yeniden kullanımının yapısal sınırlamasıdır (Bölüm 6). Ayrıca test karışımlarının önemli bir kısmında hedef sınıf karışımına baskındır (SI-SDR mix >30 dB); bu durumlarda herhangi bir maskeleme dalga-formu skorunu algısal olarak doğru olsa bile düşürür. v2.6’nın görece yüksek değeri (−15.73 dB), hedefin zaten baskın olduğu FSD50K örneklerinin sayısal yanlılığından kaynaklanmaktadır.

5.3. Algılama F1 Analizi

Algılama makro-F1’i, mimari ve veri kararlarına güçlü biçimde bağlıdır: v2.3’te FSD50K hayalet sınıfları nedeniyle 0.02’ye çökmüş, v2.4’te allow-list ile 0.09’a, v2.6’da algılama başlığıyla 0.17’ye ve v2.8’de BCE + FSD50K-çıkarmıyla 0.32’ye yükselmiştir. Sınıf-bazlı kırılımlar, her sürüm için ilgili per_version şekillerinde sunulmaktadır (Bölüm 4’deki yer tutucular).

5.4. Per-Class Analiz ve Excel Çıktısı

Her ölçülen sürüm için üç sınıf-bazlı şekil üretilir: algılama F1 (yatay çubuk), SI-SDRi (yatay çubuk) ve precision-recall saçılımı. Tüm ham sayılar ayrıca thesis_results/tables/snc_results.xlsx çalışma kitabında bir karşılaştırma sayfası ve sürüm-başına algılama/SI-SDR sayfaları olarak saklanır. Bu çıktılar, projenin ekinde tam tablolar olarak verilebilir.

6. Tartışma

6.1. SI-SDR Neden Negatif Kalıyor?

SI-SDRi’nin tüm sürümlerde negatif olması ilk bakışta modelin ayırtırmadığı izlenimini verse de, bu metriğin ölçtüğü şey izole stem’in dalga-formu düzeyinde yeniden kurgulanmasıdır. Sistem, maske karışım-genliği yaklaşımıyla genlik düzeyinde makul maskeler üretse bile, dalga formuna dönüştürme karışımının fazını yeniden kullanır. Hedef ile karışım fazı arasındaki uyumsuzluk, SI-SDR’yi cezalandırır. Dahası, hedefin baskın olduğu karışımlarda (xs) “hiçbir şey yapmama” temeli zaten çok yüksek bir SI-SDR verir; bu durumda iyileştirme (SI-SDRi) için çok az pay kalır.

6.2. Spektrogram-Faz Sınırlaması

Yalnızca-genlik maskelemesi ve karışım-fazı yeniden kullanımı, spektrogram tabanlı ayırtırmanın bilinen bir tavanıdır. Karmaşık maskeleme, faz-duyarlı maskeleme veya

doğrudan zaman alanı ayrıştırma (ör. Conv-TasNet [2], Wave-U-Net [4]) bu tavanı aşmak için doğal adımlardır (Bölüm 7).

6.3. Hayalet Yanlış-Pozitif Problemi

v2.3–v2.6 boyunca gözlemlenen en öğretici olgu, yerel sesi olmayan FSD50K sınıflarının hayalet yanlış pozitifler üretmesidir. Bu sınıflar değerlendirme karışımlarında asla bulunamadığından yalnızca FP'ye katkı verir. Minimum-klip tabanı (v2.4) ve allow-list (v2.6) bu sorunu hafifletmiş; ancak yapısal çözüm, FSD50K'nın tamamen çıkarılması (v2.8) olmuştur. Bu, “daha çok veri her zaman daha iyidir” sezgisinin, sınıf-kışullu algılama bağlamında her zaman geçerli olmadığını gösterir: yerel olarak doğrulanamayan, zayıf-örneklenmiş sınıflar denetim sinyalinı kirlendir.

6.4. Algılama ve Ayrıştırma Arasındaki Denge

Algılama F1'ini öne çıkarmak (yüksek detection_loss_weight) ile ayrıştırma kalitesini korumak arasında bir denge vardır. Bu projenin önceliğı, sunumda tutarlı ve doğrulanabilir değerler veren bir algılama başarımıdır; ayrıştırma L1'i (ağırlık 1.0) ise web uygulamasındaki çıkarılan-stem oynatımını duyulabilir tutacak kadar yüksek bırakılmıştır.

7. Gelecek Çalışmalar

- Faz-duyarlı ve karmaşık maskeleme. Karışım fazını yeniden kullanmak yerine karmaşık-değerli maskeler veya faz-duyarlı kayıplar kullanmak, SI-SDR tavanını yükseltebilir.
- Zaman alanı ayrıştırma. Conv-TasNet [2] veya Wave-U-Net [4] gibi doğrudan dalga-formu modelleri, spektrogram-faz sınırlamasını tümüyle aşar.
- Çok-çözünürlüklü STFT kaybı. Genlik L1'ine ek olarak çok-çözünürlüklü STFT kaybı, algısal kaliteyi iyileştirebilir.
- Daha güçlü algılama omurgası. PANNs [24] gibi önceden eğitilmiş ses-etiketleme ağırları, algılama başlığını besleyen daha zengin gömme uzayları sağlayabilir.
- Transformer tabanlı koşullandırma. FiLM yerine veya ona ek olarak dikkat-tabanlı (attention) koşullandırma, çok-sınıflı sorgulara ölçeklenebilir.
- Algısal ve öznel değerlendirme. SI-SDR'ye ek olarak PESQ/STOI benzeri algısal metrikler ve bir kullanıcı dinleme çalışması (MUSHRA), sistemin gerçek faydasını daha iyi yansıtacaktır.
- Çoklu-sınıf eşzamanlı sorgu. Şu anda her sınıf için ayrı çıkarım yapılmaktadır; tek

geçişte çoklu-sınıf bastırma, gecikmeyi azaltır.

- FSD50K'nın denetimli yeniden dahli. FSD50K sınıfları, yerel doğrulanabilir negatiflerle dengeli biçimde yeniden eklenirse, hayalet-FP olmadan kelime dağılımı genişletilebilir.

8. Sonuç

Bu projede, seçici gürültü engelleme için sorgu-koşullu, FiLM-temelli bir U-Net ayrıştırma sistemi tasarlanmış, on sürümlük iteratif bir süreçle geliştirilmiş ve sistematik olarak değerlendirilmiştir. Çalışmanın merkezî katkısı, yalnızca bir nihai model değil, her sürümün başarısızlık modlarının kök-neden analiziyle belgelendiği şeffaf bir mühendislik anlatısıdır: agresif artırma kaynaklı çöküş (v2.0), FSD50K hayalet yanlış-pozitifleri (v2.3–v2.6) ve focal loss gradyan çöküşü (v2.7) gibi olgular, her biri bir sonraki tasarım kararını yönlendirmiştir. Algılama makro-F1'i, mimari ve veri iyileştirmeleriyle v2.6'daki 0.17'den v2.8'de 0.32'ye yükselmiştir. Ayrıştırma metriği SI-SDRi'nin negatif kalması, spektrogram-faz yeniden kullanımının yapısal bir sınırı olarak tartışılmış ve gelecek çalışmalar için somut yönler belirlenmiştir. Sonuç olarak, çalışan bir prototip ortaya konmuş ve seçici gürültü engellemenin uçtan uca bir hattı — algılamadan video remux'a — gösterilmiştir.

KAYNAKLAR

- [1] J. R. Hershey, Z. Chen, J. L. Roux, ve S. Watanabe, “Deep clustering: Discriminative embeddings for segmentation and separation”, 18 Ağustos 2015, *arXiv*: arXiv:1508.04306. doi: 10.48550/arXiv.1508.04306.
- [2] Y. Luo ve N. Mesgarani, “Conv-TasNet: Surpassing Ideal Time-Frequency Magnitude Masking for Speech Separation”, *IEEE/ACM Trans. Audio Speech Lang. Process.*, c. 27, sy. 8, ss. 1256-1266, Ağu. 2019, doi: 10.1109/TASLP.2019.2915167.
- [3] A. Jansson, E. Humphrey, N. Montecchio, R. Bittner, A. Kumar, ve T. Weyde, “SINGING VOICE SEPARATION WITH DEEP U-NET CONVOLUTIONAL NETWORKS”.
- [4] D. Stoller, S. Ewert, ve S. Dixon, “Wave-U-Net: A Multi-Scale Neural Network for End-to-End Audio Source Separation”, 08 Haziran 2018, *arXiv*: arXiv:1806.03185. doi: 10.48550/arXiv.1806.03185.
- [5] D. Wang ve J. Chen, “Supervised Speech Separation Based on Deep Learning: An Overview”, 15 Haziran 2018, *arXiv*: arXiv:1708.07524. doi: 10.48550/arXiv.1708.07524.
- [6] D. Griffin ve Jae Lim, “Signal estimation from modified short-time Fourier transform”, *IEEE Trans. Acoust. Speech Signal Process.*, c. 32, sy. 2, ss. 236-243, Nis. 1984, doi: 10.1109/TASSP.1984.1164317.
- [7] O. Ronneberger, P. Fischer, ve T. Brox, “U-Net: Convolutional Networks for Biomedical Image Segmentation”, 18 Mayıs 2015, *arXiv*: arXiv:1505.04597. doi: 10.48550/arXiv.1505.04597.
- [8] E. Perez, F. Strub, H. de Vries, V. Dumoulin, ve A. Courville, “FiLM: Visual Reasoning with a General Conditioning Layer”, 18 Aralık 2017, *arXiv*: arXiv:1709.07871. doi: 10.48550/arXiv.1709.07871.
- [9] V. Dumoulin *vd.*, “Feature-wise transformations”, *Distill*, c. 3, sy. 7, s. 10.23915/distill.00011, Tem. 2018, doi: 10.23915/distill.00011.
- [10] G. Meseguer-Brocal ve G. Peeters, “Conditioned-U-Net: Introducing a Control Mechanism in the U-Net for Multiple Source Separations”, Kas. 2019, doi: 10.5281/zenodo.3527766.
- [11] K. Zmolikova *vd.*, “SpeakerBeam: Speaker Aware Neural Network for Target Speaker Extraction in Speech Mixtures”, *IEEE J. Sel. Top. Signal Process.*, c. 13, sy. 4, ss. 800-814, Ağu. 2019, doi: 10.1109/JSTSP.2019.2922820.
- [12] T. Ochiai, M. Delcroix, Y. Koizumi, H. Ito, K. Kinoshita, ve S. Araki, “Listen to What You Want: Neural Network-based Universal Sound Selector”, 10 Haziran 2020, *arXiv*: arXiv:2006.05712. doi: 10.48550/arXiv.2006.05712.
- [13] I. Kavalero *vd.*, “Universal Sound Separation”, 02 Ağustos 2019, *arXiv*: arXiv:1905.03330. doi: 10.48550/arXiv.1905.03330.
- [14] E. Tzinis, S. Wisdom, J. R. Hershey, A. Jansen, ve D. P. W. Ellis, “Improving Universal Sound Separation Using Sound Classification”, içinde *ICASSP 2020 - 2020 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP)*, May.

2020, ss. 96-100. doi: 10.1109/ICASSP40776.2020.9053921.

- [15] S. Wisdom, E. Tzinis, H. Erdogan, R. J. Weiss, K. Wilson, ve J. R. Hershey, “Unsupervised Sound Separation Using Mixture Invariant Training”, 24 Ekim 2020, *arXiv*: arXiv:2006.12701. doi: 10.48550/arXiv.2006.12701.
- [16] J. L. Roux, S. Wisdom, H. Erdogan, ve J. R. Hershey, “SDR - half-baked or well done?”, 06 Kasım 2018, *arXiv*: arXiv:1811.02508. doi: 10.48550/arXiv.1811.02508.
- [17] E. Vincent, R. Gribonval, ve C. Fevotte, “Performance measurement in blind audio source separation”, *IEEE Trans. Audio Speech Lang. Process.*, c. 14, sy. 4, ss. 1462-1469, Tem. 2006, doi: 10.1109/TSA.2005.858005.
- [18] K. J. Piczak, “ESC: Dataset for Environmental Sound Classification”, içinde *Proceedings of the 23rd ACM international conference on Multimedia*, Brisbane Australia: ACM, Eki. 2015, ss. 1015-1018. doi: 10.1145/2733373.2806390.
- [19] J. Salamon, C. Jacoby, ve J. P. Bello, “A Dataset and Taxonomy for Urban Sound Research”, içinde *Proceedings of the 22nd ACM international conference on Multimedia*, Orlando Florida USA: ACM, Kas. 2014, ss. 1041-1044. doi: 10.1145/2647868.2655045.
- [20] E. Fonseca, X. Favory, J. Pons, F. Font, ve X. Serra, “FSD50K: An Open Dataset of Human-Labeled Sound Events”, 23 Nisan 2022, *arXiv*: arXiv:2010.00475. doi: 10.48550/arXiv.2010.00475.
- [21] S. Ioffe ve C. Szegedy, “Batch Normalization: Accelerating Deep Network Training by Reducing Internal Covariate Shift”, 02 Mart 2015, *arXiv*: arXiv:1502.03167. doi: 10.48550/arXiv.1502.03167.
- [22] T.-Y. Lin, P. Goyal, R. Girshick, K. He, ve P. Dollár, “Focal Loss for Dense Object Detection”, 07 Şubat 2018, *arXiv*: arXiv:1708.02002. doi: 10.48550/arXiv.1708.02002.
- [23] D. P. Kingma ve J. Ba, “Adam: A Method for Stochastic Optimization”, 30 Ocak 2017, *arXiv*: arXiv:1412.6980. doi: 10.48550/arXiv.1412.6980.
- [24] Q. Kong, Y. Cao, T. Iqbal, Y. Wang, W. Wang, ve M. D. Plumbley, “PANNs: Large-Scale Pretrained Audio Neural Networks for Audio Pattern Recognition”, 23 Ağustos 2020, *arXiv*: arXiv:1912.10211. doi: 10.48550/arXiv.1912.10211.